

МЕТОДИЧЕСКИЕ РЕКОМЕНДАЦИИ ПО ВЫПОЛНЕНИЮ СКВОЗНОГО ПРОЕКТА

ВЕХА 1. РАЗВЕДОЧНЫЙ АНАЛИЗ (EDA), ПРЕДОБРАБОТКА И СТАТИСТИЧЕСКАЯ ВЕРИФИКАЦИЯ ВРЕМЕННЫХ РЯДОВ

Проект выполняется КОМАНДОЙ, в которой каждый участник имеет свою РОЛЬ. На этапе Вехи 1 общая командная цель - сдать полностью работающий, воспроизводимый программный пайплайн очистки и первичного анализа данных.

Роль Data Analyst: осуществляет расчёт дескриптивных статистик, строит графики сезонности, декомпозиции и проводит тесты Дики-Фуллера.

Роль ML Engineer: пишет математические функции фильтрации выбросов и алгоритмы интерполяции.

Роль MLOps: настраивает изолированное виртуальное окружение и структуру папок проекта.

В итоге реализуется полноценная командная работа, где у каждого участника есть свой личный контролируемый участок фронта в общем Git-репозитории, за выполнение задач которого он получает персональные баллы на устной защите вехи перед преподавателем.

1. ВХОДНОЙ ОРГАНИЗАЦИОННЫЙ РЕГЛАМЕНТ

Перед стартом технологического конвейера проектная группа обязана выполнить три организационных условия:

1. Формирование команды: студенты организуют устойчивые микрогруппы численностью от 3 до 4 человек. Внутри группы происходит распределение и фиксация ролей (Data Analyst, ML Engineer, MLOps).

2. Фиксация индустриального домена: команда выбирает один инвариантный (неизменяемый) кейс из предложенных вариантов (Вариант 1 - T1 или Вариант 2 - Спортмастер). Смена датасета, предметной области или направления исследования в процессе дальнейшего обучения категорически запрещена.

3. Инициализация среды: MLOps-инженер команды разворачивает изолированное окружение разработки (venv или Poetry), фиксирует базовый аналитический стек (Python $\geq$ 3.10, pandas, numpy, matplotlib, seaborn, statsmodels, sktime) и выкачивает сырой массив данных по ссылкам из Раздела 4 дисциплины.

2. ЦЕЛЬ И ЗАДАЧИ ВЕХИ 1

Цель работы - проведение комплексного углубленного разведочного анализа (EDA) исходного временного ряда, его программная очистка от технического шума, латентных пропусков (лакун) и экстремальных выбросов, структурная декомпозиция ряда на изолированные компоненты и строгое математическое доказательство его стационарности без эффекта «заглядывания в будущее».

Задачи вехи:

1. Осуществить корректный программный импорт данных, выстроить временную индексацию и провести аудит качества сырого массива (поиск пропусков, дубликатов, аномалий).

2. Разработать, протестировать и программно обосновать изолированный переиспользуемый модуль автоматической фильтрации выбросов и интерполяции лакун данных.

3. Провести графический анализ временной структуры на различных масштабах упреждения и осуществить STL-декомпозицию ряда.

4. Провести автокорреляционный анализ (ACF/PACF) для точного определения глубины исторической памяти и лаговых зависимостей динамической системы динамической системы.

5. Выполнить комплексное статистическое тестирование на стационарность (сочетание тестов ADF и KPSS) и математически обосновать порядок интегрируемости временного ряда.

3. ПОШАГОВЫЙ ХОД ВЫПОЛНЕНИЯ РАБОТЫ ДЛЯ СТУДЕНТОВ

Этап 1. Первичный аудит и профилирование

Действия студентов. загрузить сырой .csv-файл. Провести программную проверку типов данных во всех колонках. Принудительно привести временную ось к типу данных DateTime. Установить данную временную колонку в качестве главного индекса DataFrame. Выполнить сортировку данных по строго хронологической оси. Рассчитать базовую матрицу дескриптивных статистик (среднее, медиана, квантили, стандартное отклонение).

Зона ответственности. Data Analyst осуществляет импорт, строит первичное распределение плотности величин и фиксирует базовые статистики; MLOps настраивает структуру каталогов и контролирует отсутствие конфликтов памяти при загрузке тяжелых файлов логов или транзакций ритейла.

Этап 2. Статистическая фильтрация и заполнение лакун

Действия студентов. Написать скрипт для автоматического сканирования пропущенных временных меток (поиск дыр в хронологии). Реализовать алгоритм автоматической фильтрации экстремальных выбросов с использованием правила трех сигм (для нормально распределенного шума) или межквартильного размаха (IQR для асимметричных распределений). Для заполнения обнаруженных лакун программно применить и математически обосновать метод интерполяции (например, линейную или сплайновую интерполяцию для высокочастотных логов серверов T1, либо метод FFILL / скользящие медианы для посуточных продаж Спортмастера).

Критическое ограничение. Категорически запрещено использовать будущие значения ряда (информацию из «будущего») для заполнения текущих пропусков во избежание смещения оценок и эффекта заглядывания в будущее.

Зона ответственности. ML-инженер разрабатывает чистые функции очистки и интерполяции; Data Analyst верифицирует результаты работы алгоритма и доказывает, что после фильтрации не исказились исходные стохастические свойства ряда. L-инженер разрабатывает функции очистки; Data Analyst верифицирует, что после фильтрации не исказились стохастические свойства ряда.

Этап 3. Структурная декомпозиция и ACF/PACF анализ

Действия студентов. Построить графики ряда на трех различных масштабах: за весь исторический период (поиск глобального векового тренда), за месяц (недельная цикличность — будни против выходных) и за сутки (для минутных логов T1 — поиск внутрисуточных профилей пиковой нагрузки). С помощью алгоритма STL-декомпозиции из библиотеки statsmodels разложить ряд на три составляющие: Тренд (Trend), Сезонность (Seasonal) и Случайный остаток (Resid). Построить графики автокорреляционной (ACF) и частной автокорреляционной (PACF) функций. Выделить и выписать номера лагов, выходящих за границы доверительного интервала.

Зона ответственности. Исполняется совместно Data Analyst и ML-инженером. Аналитик интерпретирует значимые лаги, сезонные циклы и находит лакуны в памяти ряда, а инженер фиксирует эти параметры для генерации будущих лаговых и скользящих признаков моделей на Веке 2.

Этап 4. Верификация стационарности

Действия студентов. Запустить обобщенный тест Дики-Фуллера (ADF-test) для проверки гипотезы о наличии единичного корня (нулевая гипотеза — ряд нестационарен).

Параллельно запустить тест KPSS (где нулевая гипотеза - ряд стационарен). На основе полученных значений p -value обоих тестов сделать строгий вывод о типе нестационарности ряда. Если ряд признан нестационарным, применить оператор взятия последовательных разностей (первых разностей $Y_t - Y_{t-1}$) или сезонных разностей) и повторить цикл тестирования до достижения строгой стационарности остаточного ряда.

Зона ответственности. Data Analyst проводит математическое обоснование результатов тестов, фиксирует финальный порядок интегрируемости ряда d и заносит все выводы в итоговый аналитический отчет.

4. РЕГЛАМЕНТ ИСПОЛЬЗОВАНИЯ ГЕНЕРАТИВНОГО ИИ (LLM-КАНОН)

Согласно этическому кодексу Университета ИТМО, использование больших языковых моделей (ChatGPT, Claude, DeepSeek и т.д.) в рамках Вехи 1 жестко регламентировано:

РАЗРЕШЕНО: Использовать LLM как интерактивный синтаксический справочник для ускорения написания шаблонного кода визуализации (matplotlib/seaborn), генерации регулярных выражений для парсинга дат и написания заготовок docstrings по стандарту PEP-8.

ЗАПРЕЩЕНО: Делегировать ИИ текстовую интерпретацию графиков ACF/PACF, STL-декомпозиции и результатов статистических тестов. Описание физического смысла трендов, причин дрейфа и выводов по значениям p -value студент обязан сформулировать в отчете исключительно **самостоятельно**. Выявление генеративного плагиата в аналитической записке аннулирует баллы за веку для всей команды.

5. КРИТЕРИИ ОЦЕНИВАНИЯ ВЕХИ 1 (РУБРИКАТОР ПРИЕМКИ)

Первая вежа оценивается преподавателем в рамках накопительной составляющей сквозного проекта по 10-балльной шкале на основе Definition of Done (DoD):

- **9–10 баллов («Отлично» / Уровень Проектировщика):**
 - Создан чистый, отчуждаемый программный модуль preprocessing.py.
 - Ноутбук eda_and_preprocessing.ipynb полностью воспроизводим, ячейки выполняются строго по порядку, код декомпозирован на функции, отсутствуют hardcoded-пути.
 - Все графики имеют подписи осей с указанием единиц измерения, легенду и развернутые текстовые выводы.
 - Выбросы и пропуски устранены без эффекта *data leakage*.
 - Математически доказана стационарность преобразованного ряда на основе синергии тестов ADF и KPSS, определен точный порядок интегрируемости ряда.
- **6–8 баллов («Хорошо» / Уровень Самостоятельного разработчика):**
 - Разведочный анализ выполнен в полном объеме, графики декомпозиции и автокорреляции построены корректно.
 - Пропуски заполнены, однако выбор метода интерполяции носит шаблонный характер без глубокого индустриального обоснования.
 - Тестирование на стационарность проведено (запущен ADF-тест), однако отсутствует перекрестная проверка тестом KPSS, или выводы по значениям p -value содержат незначительные методические ошибки.
 - Код работает, но нарушает PEP-8 или содержит избыточные дублирующиеся куски.
- **4–5 баллов («Удовлетворительно» / Уровень Исполнителя по инструкции):**
 - **Нижний блокирующий порог.** Студент по готовому шаблону загрузил данные, построил базовый график временного ряда и скользящего среднего.

- Данные содержат неотфильтрованные аномалии, или пропуски были просто удалены из таблицы (что нарушает целостность временной структуры ряда).
- STL-декомпозиция или графики ACF/PACF отсутствуют, либо студент не смог устно объяснить их математический смысл на защите.
- **0–3 балла («Неудовлетворительно»):**
 - Пайплайн не запускается, выдает критические ошибки.
 - Допущена грубейшая методологическая ошибка *data leakage* (использование будущих точек для чистки прошлого).
 - Обнаружен полный плагиат кода или аналитического текста, сгенерированного LLM без самостоятельного осмысления.