

МЕТОДИЧЕСКИЕ РЕКОМЕНДАЦИИ ПО ВЫПОЛНЕНИЮ СКВОЗНОГО ПРОЕКТА

ВЕХА 2. СТАТИСТИЧЕСКОЕ И КЛАССИЧЕСКОЕ МАШИННОЕ ОБУЧЕНИЕ НА ВРЕМЕННЫХ РЯДАХ

Проект выполняется **КОМАНДОЙ**, в которой каждый участник имеет свою **РОЛЬ**. На этапе Вехи 2 общая командная цель - построить, оптимизировать и сравнить между собой классическую статистическую параметрическую модель и индустриальные ансамбли машинного обучения на основе градиентного бустинга.

- Роль Data Analyst: Отвечает за математическую идентификацию параметров классической авторегрессии (p , d , q), статистический анализ остатков моделей и интерпретацию вклада признаков (*Feature Importance*).
- Роль ML Engineer: Проектирует сквозной пайплайн генерации признаков скользящего окна, настраивает схемы кросс-валидации без утечки данных, обучает ансамбли и проводит автоматический подбор гиперпараметров.
- Роль MLOps: Обеспечивает интеграцию очищенного датасета из Вехи 1, контролирует модульную структуру кода новых скриптов, минимизирует вычислительную сложность при генерации признаков.

1. ВХОДНОЙ ОРГАНИЗАЦИОННЫЙ РЕГЛАМЕНТ

Перед стартом моделирования на Вехе 2 проектная группа обязана выполнить три обязательных условия:

1. **Импорт очищенного базиса.** Команда подключает итерационный модуль предобработки `preprocessing.py`, разработанный на Вехе 1. Использование сырых, неотфильтрованных данных на этом этапе категорически запрещено.
2. **Фиксация метрик.** Команда фиксирует ключевую метрику оценки качества регрессии (RMSE, MAE, MAPE или WAPE) в строгом соответствии со спецификой своего индустриального кейса (утилизация ИИ-кластеров Т1 или товарооборот Спортмастера).
3. **Контроль разделения данных.** MLOps-инженер фиксирует границы отсечения данных на обучающую (*train*) и отложенную валидационную (*validation*) выборки по хронологической оси для проведения честного тестирования.

2. ЦЕЛЬ И ЗАДАЧИ ВЕХИ 2

Цель работы - разработка, математическое обоснование, программная реализация и сравнительный анализ прогнозных пайплайнов на базе классических линейных стохастических моделей (ARIMA/SARIMA) и современных промышленных алгоритмов градиентного бустинга над деревьями решений (CatBoost / LightGBM) с обеспечением строгой временной валидации без эффекта «заглядывания в будущее» (*data leakage*).

Задачи вехи:

- Осуществить подбор структурных параметров линейной модели (p , d , q) на основе визуального анализа графиков ACF/PACF и информационных критериев (AIC/BIC).
- Обучить baseline-модель авторегрессии и провести комплексный статистический аудит её остатков на соответствие свойствам «белого шума».
- Разработать и программно автоматизировать пайплайн генерации признаков (*Feature Engineering*) из временных окон: лаги, скользящие агрегаты и экзогенные переменные (погода/календарь промо-акций).
- Реализовать корректную схему валидации моделей на данных с временной структурой с использованием блокирующего разбиения или кросс-валидации со сдвигом по времени (TimeSeriesSplit).

- Провести оптимизацию гиперпараметров алгоритмов градиентного бустинга с использованием фреймворка Optuna, сформировать сводную аналитическую таблицу качества моделей и обосновать выбор лучшего алгоритма.

3. ХОД ВЫПОЛНЕНИЯ РАБОТЫ ДЛЯ СТУДЕНТОВ

Этап 1. Идентификация и построение моделей ARIMA/SARIMA

Действия студентов: используя графики автокорреляции (ACF) и частной автокорреляции (PACF), полученные на Вехе 1, определить начальные границы порядков авторегрессии (p) и скользящего среднего (q). Запустить сеточный поиск (*Grid Search* на базе библиотеки statsmodels или автоматический подбор pmdarima) для минимизации информационного критерия Акаике (AIC). Обучить финальную модель ARIMA/SARIMA. Построить графики остатков модели: проверить их на отсутствие автокорреляции (тест Льюнга-Бокса) и соответствие нормальному распределению.

Зона ответственности ролей: *Data Analyst* проводит математическую идентификацию параметров, оценивает остатки и строит доверительные интервалы прогноза; *ML-инженер* оборачивает обучение в воспроизводимый класс.

Этап 2. Проектирование матрицы признаков (Feature Engineering)

Действия студентов: трансформировать задачу прогнозирования временного ряда в классическую задачу обучения с учителем (*Supervised Learning*). Написать функцию автоматической генерации признаков методом скользящего окна. Сгенерировать:

1. *Лаговые переменные (Lags)* на основе значимых лагов из ACF.
2. *Скользящие статистики (Rolling)*: скользящее среднее, медиану и стандартное отклонение по окнам различной ширины.
3. *Календарные фичи*: день недели, месяц, маркеры выходных дней.
4. *Экзогенные признаки (Exogenous)*: подключить данные о погоде (для трафика/метро) или индикаторы скидочных промо-программ Спортмастера из файла calendar.csv.

Критическое ограничение: запрещено рассчитывать скользящие статистики, включающие текущую или будущие точки прогноза. Все лаги и окна должны быть строго сдвинуты назад во времени, иначе возникнет неустраняемая утечка данных (*data leakage*).

Зона ответственности ролей: *ML-инженер* полностью автоматизирует пайплайн генерации признаков в виде скрипта; *MLOps* контролирует скорость выполнения кода (оптимизирует операции над pandas.DataFrame).

Этап 3. Валидация и ансамблирование (Градиентный бустинг)

Действия студентов: развернуть пайплайн обучения моделей градиентного бустинга (CatBoost или LightGBM). Настроить схему валидации TimeSeriesSplit из библиотеки scikit-learn минимум на 5 фолдов. Интегрировать фреймворк Optuna для автоматического подбора критических гиперпараметров (глубина деревьев, скорость обучения, регуляризация) в рамках 100 итераций. Обучить оптимизированную модель. Если это предусмотрено кейсом ритейла (Спортмастер), переписать стандартную функцию потерь (MSE) на асимметричный Quantile Loss для управления рисками дефицита на складах.

Зона ответственности ролей: *ML-инженер* настраивает кросс-валидацию и интеграцию с Optuna; *Data Analyst* рассчитывает финальные метрики на отложенной выборке и строит графики важности признаков (*SHAP values* или встроенный *Feature Importance*).

4. РЕГЛАМЕНТ ИСПОЛЬЗОВАНИЯ ГЕНЕРАТИВНОГО ИИ (LLM-КАНОН)

Использование больших языковых моделей (ChatGPT, Claude, DeepSeek и т.д.) в рамках Вехи 2 строго регламентировано:

- **РАЗРЕШЕНО:** Использовать LLM как инструмент быстрого написания рутинного кода: синтаксис циклов для кросс-валидации TimeSeriesSplit, шаблоны функций генерации лагов в pandas, создание скрипта конфигурации поиска гиперпараметров для Optuna objective function .

- **ЗАПРЕЩЕНО:** Делегировать ИИ обоснование выбора конкретной метрики под бизнес-задачу, математический анализ остатков авторегрессии и финальное сравнение алгоритмов. Студент обязан **самостоятельно** доказать на устной защите, почему градиентный бустинг превзошел (или уступил) модель ARIMA на конкретном датасете, и объяснить физический смысл сгенерированных лагов.

5. КРИТЕРИИ ОЦЕНИВАНИЯ ВЕХИ 2 (РУБРИКАТОР ПРИЕМКИ)

Вторая веха оценивается преподавателем по 10-балльной шкале на основе Definition of Done (DoD) :

- **9–10 баллов («Отлично» / Уровень Проектировщика):**
 - Создан чистый, отчуждаемый программный модуль models.py (или train.py), запускающий весь цикл обучения и подбора параметров .
 - Реализована корректная схема кросс-валидации TimeSeriesSplit, полностью исключающая заглядывание в будущее .
 - Пайплайн Feature Engineering полностью автоматизирован, добавлены экзогенные факторы (промо/погода) .
 - Успешно проведена оптимизация гиперпараметров через Optuna . Остатки ARIMA проверены статистически.
 - Для кейса Спортмастера модель успешно переведена и обучена под кастомную функцию потерь *Quantile Loss* .
- **6–8 баллов («Хорошо» / Уровень Самостоятельного разработчика):**
 - Обучены обе модели (ARIMA и CatBoost), графики прогнозов построены корректно, метрики рассчитаны правильно.
 - Генерация признаков выполнена, однако ограничилась только простейшими лагами (без учета сложных скользящих окон или экзогенных факторов).
 - Подбор гиперпараметров выполнен вручную по сетке (*GridSearch*) без использования продвинутой автоматизации Optuna, либо валидация проведена по простому фиксированному временному отсечению (без кросс-валидации на фолдах) .
 - Код полностью рабочий, но нарушает стандарты PEP-8 или содержит жестко зашитые локальные пути к файлам.
- **4–5 баллов («Удовлетворительно» / Уровень Исполнителя по инструкции):**
 - **Нижний блокирующий порог.** Студент по готовому интернет-тutorиалу обучил модель линейной регрессии или базовый бустинг на временном ряду.
 - Допущены ошибки при формировании матрицы признаков, приведшие к частичной потере хронологии ряда.
 - Валидация проведена как на обычных табличных данных (случайное перемешивание train_test_split), что привело к тотальной утечке данных (*data leakage*). Модель ARIMA или графики остатков отсутствуют.
- **0–3 балла («Неудовлетворительно»):**
 - Программный пайплайн не запускается, выдает критические ошибки при попытке генерации окон.
 - Допущена сквозная утечка данных (*data leakage*), исказившая реальное качество моделей.
 - Обнаружен полный плагиат чужого кода или аналитического текста, сгенерированного LLM без самостоятельного участия команды.